

Análisis y predicción del volumen de tráfico por hora en la I-94

Regresión lineal manual y Random Forest con scikit-learn

Jose Eduardo Perez Abundiz · A01666860

Instituto Tecnológico y de Estudios Superiores de Monterrey, Campus Querétaro

Inteligencia artificial avanzada para la ciencia de datos (Gpo 601)

Profesor: Dr. Benjamín Valdés

Resumen. Se estimó el volumen vehicular horario mediante una regresión lineal múltiple programada manualmente y un Random Forest implementado con scikit-learn. El ETL consolidó 48,204 registros en 40,564 horas y 70 entradas. En prueba, la regresión obtuvo R^2 de 0.8400 y MAE de 583.60 vehículos, mientras que Random Forest alcanzó R^2 de 0.9594 y MAE de 238.61. Se analizan los errores por horario, el ajuste de hiperparámetros y la importancia relativa de grupos de variables.

Palabras clave / Keywords: volumen de tráfico; regresión lineal múltiple; Random Forest; ETL; aprendizaje automático; evaluación de modelos.

1. Introducción

1.1 Objetivo general

Analizar y predecir el volumen de tráfico por hora en el tramo oeste de la I-94, identificando patrones temporales y evaluando si las condiciones climáticas y los días festivos están asociados con cambios en el tráfico.

1.2 Justificación

Estimar el volumen de tráfico por hora puede aportar información útil para la planeación de viajes y de actividades de mantenimiento vial. Identificar los horarios con mayor volumen vehicular permitiría apoyar la elaboración de avisos anticipados para los conductores. Asimismo, reconocer periodos de menor volumen esperado podría ayudar a seleccionar horarios de mantenimiento que afecten a menos usuarios, considerando la duración completa de los trabajos.

Estas aplicaciones representan usos potenciales del proyecto. Las predicciones tendrían que complementarse con información sobre las condiciones de operación y seguridad de la vía. El volumen vehicular, por sí solo, no permite determinar la existencia de congestión ni identificar rutas alternativas óptimas. La eficacia de estas aplicaciones operativas todavía no ha sido evaluada.

1.3 Planteamiento del problema

El proyecto estudia la estimación del número de vehículos por hora a partir de información temporal, meteorológica y de festividades. Primero se implementa una regresión lineal múltiple sin framework de aprendizaje automático para documentar directamente la función de costo, los gradientes y la actualización de parámetros. Después se utiliza RandomForestRegressor de scikit-learn para representar relaciones no lineales e interacciones que el modelo aditivo manual no puede aprender por sí mismo. Ambos modelos utilizan el mismo dataset preparado y la misma separación cronológica, lo que permite comparar sus resultados bajo condiciones equivalentes.

El análisis utiliza condiciones meteorológicas históricas observadas. Los pronósticos meteorológicos y la validación operativa de avisos anticipados quedan fuera del alcance de

este reporte. Tampoco se interpretan las asociaciones como relaciones causales.

2. Descripción del dataset

Se utiliza Metro Interstate Traffic Volume, publicado por John Hogue en UCI Machine Learning Repository en 2019. La fuente identifica la estación MN DoT ATR 301, en el sentido oeste de la I-94 entre Minneapolis y Saint Paul, Minnesota. El archivo contiene 48,204 registros y nueve columnas: ocho entradas originales y la variable objetivo traffic_volume. Las fechas abarcan del 2 de octubre de 2012 a las 09:00 al 30 de septiembre de 2018 a las 23:00. UCI describe las marcas temporales como hora local CST; esta descripción se conserva sin inferir ajustes adicionales de zona horaria. [1]

Tabla 1. Variables originales y unidades

Variable	Contenido y unidad
holiday	Nombre de festividad o cadena literal None
temp	Temperatura en kelvin
rain_1h	Lluvia en milímetros durante una hora
snow_1h	Nieve en milímetros durante una hora
clouds_all	Nubosidad en porcentaje
weather_main	Categoría meteorológica general
weather_description	Descripción meteorológica detallada
date_time	Fecha y hora del registro
traffic_volume	Volumen vehicular por hora; variable objetivo

Aunque la fuente indica ausencia de valores faltantes, esto no garantiza que todos los valores sean válidos ni que exista una sola fila por hora. Ambas condiciones se revisaron durante el ETL.

3. Proceso de extracción, transformación y carga (ETL)

3.1 Extracción y revisión inicial

El CSV se leyó con Pandas usando `keep_default_na=False` para conservar None como texto en holiday, en lugar de interpretarlo automáticamente como un valor faltante. La inspección inicial identificó cinco columnas numéricas y cuatro de texto, con 48,204 valores no nulos por columna. No se encontraron cadenas vacías ni compuestas únicamente por espacios en holiday, weather_main, weather_description o date_time.

Se revisaron las unidades, rangos, frecuencias y registros vecinos de valores sospechosos. La ausencia de nulos se trató como un resultado de integridad del archivo, no como una validación suficiente de su contenido.

3.2 Limpieza y justificación de decisiones

La tabla siguiente sintetiza las decisiones adoptadas. Las comprobaciones numéricas corresponden al desarrollo documentado en el notebook v2.

Tabla 2. Decisiones de limpieza

Registro	Diez temperaturas de 0 K
Decisión y fundamento	Eliminar las filas: son incompatibles con temperatura ambiental y representan aproximadamente 0.021% del archivo. Imputar habría introducido valores estimados.
Efecto o limitación	Quedan 48,194 filas. No se conoce la causa del registro inválido.
Registro	Una lluvia de 9,831.3 mm/h
Decisión y fundamento	Eliminar la fila por su magnitud anómala y su carácter aislado frente a registros vecinos de 0 mm. La etiqueta de tormenta no valida esa cantidad.
Efecto o limitación	Quedan 48,193 filas. No se ha demostrado una mejora predictiva atribuible a esta eliminación.
Registro	snow_1h con escasos positivos, concentrados temporalmente
Decisión y fundamento	Excluir la columna como simplificación de esta versión.
Efecto o limitación	No implica que la nieve sea irrelevante; permanece información sobre nieve en las descripciones meteorológicas.
Registro	clouds_all entre 0 y 100
Decisión y fundamento	Conservar la variable al no encontrar valores fuera de su rango porcentual.
Efecto o limitación	Las discrepancias entre registros de una misma hora requieren agregación posterior.
Registro	Variantes de escritura en weather_description
Decisión y fundamento	Eliminar espacios externos y convertir a minúsculas.
Efecto o limitación	Las categorías pasan de 38 a 37; se unifican variantes de sky is clear.

Los ceros de temperatura se concentran el 31 de enero de 2014, de 03:00 a 06:00, y el 2 de febrero de 2014, de 03:00 a 08:00. Las observaciones vecinas presentaban valores cercanos a 255 K, incluidos 255.93, 255.37 y 255.62 K. Este contraste respalda considerarlos inválidos, pero no permite atribuirlos a una falla específica del sensor.

La lluvia anómala corresponde al 11 de julio de 2016 a las 17:00. Al retirar esa fila, el máximo de rain_1h pasa de 9,831.3 a 55.63 mm; la media, de 0.334333 a 0.130342; y la desviación estándar, de 44.793779 a 1.003480. Estos cambios describen su influencia sobre la distribución, sin demostrar por sí mismos un efecto sobre la calidad del modelo.

Para nieve se identificaron 63 registros positivos, correspondientes a 31 horas de las 40,564 finales, aproximadamente 0.076%. Se concentraban en siete fechas: 23, 26, 28 y 29 de diciembre de 2015, y 6, 7 y 8 de enero de 2016. A la vez, weather_main contenía 2,876 registros etiquetados como Snow. Esta diferencia advierte que las etiquetas meteorológicas y las cantidades positivas de nieve no son equivalentes; la escasez de snow_1h no demuestra ausencia de condiciones de nieve.

3.3 Transformación de variables

Festividades. Dentro del intervalo conocido del archivo, del 2 de octubre de 2012 al 30 de septiembre de 2018, se encontraron 48,143 registros con None y 61 con nombres de festividades. Estos últimos aparecen a medianoche y corresponden a 53 fechas únicas. Antes de eliminar filas se identificaron esas fechas y se asignó un indicador a todos sus registros horarios: 1,409 filas quedaron con valor 1 y 46,795 con valor 0. Se conservaron las 53 fechas identificadas y no quedaron fechas con indicadores mezclados. No se contrastaron las etiquetas con un calendario externo: la incertidumbre se refiere a su cobertura de festividades, no al periodo del dataset.

La variable conserva el nombre holiday, ahora binario. Esta transformación representa pertenencia a una fecha identificada como festiva en el archivo, pero pierde la identidad de cada festividad. No demuestra que el calendario sea exhaustivo ni que cada None original signifique un día ordinario.

Consolidación por hora. Antes de la limpieza había 40,575 marcas temporales distintas, 7,629 filas adicionales respecto a una fila por hora y 17 duplicados completos. Después de eliminar las once filas anómalas, permanecieron 48,193 registros para 40,564 horas. Dentro de cada hora, holiday y traffic_volume no variaban; en cambio, existían discrepancias en temperatura para 78 horas, lluvia para nueve y nubosidad para 32.

Por ello, no se conservó simplemente la primera fila de cada hora para todas las variables. Para temperatura, lluvia y nubosidad se calculó la media de sus valores distintos por hora. Esta regla heurística busca evitar que una cantidad tenga mayor peso solo por repetirse junto con más etiquetas meteorológicas. Por ejemplo, para tres registros de lluvia de 3.3 y uno de 2.54 mm, la media de valores distintos es 2.92 mm, frente a 3.11 mm al promediar todas las filas. La regla

pierde la multiplicidad de observaciones, no recupera una medición verdadera conocida y no cuenta con una mejora predictiva demostrada. Para `holiday` y `traffic_volume` se conservó el primer valor únicamente después de comprobar su igualdad dentro de cada hora.

Se examinó además la temperatura 276.793 K, presente en 78 registros de 78 horas y 14 fechas. En 74 horas no había otra temperatura disponible; en cuatro sí, con discrepancias de hasta 20.433 K. Se conservó como valor sospechoso ante la falta de evidencia para reemplazarlo y para evitar perder las 74 horas sin alternativa. La fuente no documenta su causa. En las cuatro horas con alternativa, la regla de agregación produjo 267.8765, 266.5765, 268.4865 y 268.8965 K. Para nubosidad, pares de 1 y 76, o de 1 y 75, produjeron 38.5 y 38%; las discrepancias alcanzaban 75 puntos porcentuales. Estos ejemplos muestran que la agregación no elimina la incertidumbre del dato original.

Descripciones meteorológicas. Se conservaron las descripciones detalladas y no se añadió `weather_main` como entrada adicional. Se generaron indicadores con `get_dummies` por fila y después se tomó su máximo por marca temporal. Así, una hora puede tener varios indicadores en 1: se preservan las descripciones registradas sin afirmar que todas las condiciones ocurrieran físicamente de manera simultánea. Algunas categorías solo aparecen en uno o dos eventos, lo que limita la evidencia disponible para aprender su efecto.

3.4 Resultado del ETL y carga de los datos preparados

La consolidación produjo una tabla de 40,564 filas y 42 columnas: cinco numéricas, incluida la variable objetivo, y 37 indicadores meteorológicos. Se extrajeron `hour` y `weekday` de la fecha, obteniendo 44 columnas antes de preparar la matriz del modelo. Tras la codificación descrita a continuación, el ETL exporta `trafico_limpio.csv` con 40,564 filas y 72 columnas: fecha, 70 entradas y variable objetivo. El archivo conserva las entradas sin normalizar, de modo que el escalamiento pueda ajustarse posteriormente solo con entrenamiento. No se implementaron cargas a AWS o SQL.

3.5 Exploración temporal y codificación de entradas

La exploración mostró un volumen promedio de 373.3 vehículos a las 03:00 y de 5,708.6 a las 16:00; a las 07:00 y 23:00 se observaron 4,772.1 y 1,490.7, respectivamente. Los conteos por hora del día variaron entre 1,639 y 1,740 observaciones. Por día de la semana, los promedios fueron los siguientes:

Tabla 3. Volumen promedio por día

Día	Volumen promedio
Lunes	3,313.2
Martes	3,534.7
Miércoles	3,608.3
Jueves	3,653.9
Viernes	3,675.8
Sábado	2,822.6
Domingo	2,428.0

Estos patrones motivaron representar hora y día mediante indicadores, en lugar de imponer un cambio lineal por cada incremento de su código numérico. Se utilizaron 23 indicadores horarios, con medianoche como referencia, y seis de día de semana, con lunes como referencia. La matriz final contiene 70 entradas: cuatro variables (`holiday`, `temp`, `rain_1h`, `clouds_all`), 37 indicadores meteorológicos, 23 horarios y seis de día. Se excluyen de ella el objetivo, los códigos numéricos originales de hora y día y `weather_main`.

La exploración y la definición del vocabulario meteorológico se realizaron sobre el conjunto completo antes de dividirlo. En consecuencia, la selección de representación estuvo informada por datos que posteriormente se reservaron para prueba: dicho conjunto no es completamente ajeno al desarrollo. Esta limitación se mantiene al interpretar su evaluación.

4. Implementación del modelo sin framework

La implementación se organizó en tres programas: `preparar_dataset.py` realiza el ETL y exporta el CSV limpio; `modelo_manual.py` carga ese archivo, divide cronológicamente, escala, entrena y evalúa; y `comparar_variables.py` reutiliza las funciones del modelo para comparar grupos de entradas. Los programas se acompañan de un README y un archivo de dependencias. Una vez generado el CSV limpio, el modelo puede ejecutarse sin acceder al CSV original. Esta separación permite revisar la preparación y el aprendizaje como procesos distintos.

4.1 División y escalamiento

Los registros se ordenaron cronológicamente y se dividieron en entrenamiento, validación y prueba, con proporciones aproximadas de 70%, 15% y 15%.

Tabla 4. Separación cronológica

Registro	Entrenam.
Horas	28,394
Inicio	2012-10-02 09:00
Fin	2017-05-10 07:00
Registro	Validación
Horas	6,085

Registro	Validación
Inicio	2017-05-10 08:00
Fin	2018-01-19 16:00
Registro	Prueba
Horas	6,085
Inicio	2018-01-19 17:00
Fin	2018-09-30 23:00

Temperatura, lluvia y nubosidad se transformaron mediante min-max, utilizando exclusivamente los extremos de entrenamiento: 243.39-308.24 K, 0-55.63 mm y 0-100%, respectivamente. Los indicadores no se escalan y el objetivo permaneció en vehículos por hora. La matriz de entrenamiento tiene dimensiones 28,394 × 70 y valores de punto flotante. La existencia de huecos temporales y de periodos diferentes entre conjuntos debe considerarse al interpretar sus métricas.

4.2 Formulación y aprendizaje

La regresión lineal múltiple es adecuada para representar un objetivo numérico mediante varias entradas. Sus coeficientes permiten interpretar cómo cambia la estimación al variar una entrada manteniendo las demás constantes, y su estructura facilita comparar grupos temporales, meteorológicos y de festividades. Implementarla manualmente permite examinar directamente la función de costo, sus gradientes y las actualizaciones de parámetros.

La regresión lineal múltiple se implementó manualmente con NumPy, usando operaciones matriciales @ o dot, y Pandas para la preparación de datos. La formulación lineal y la pérdida cuadrática se describen en Dive into Deep Learning, capítulo 3.1. [2] Para una matriz de entradas X, un vector de pesos w y un intercepto b, se calcula:

$$\hat{y} = Xw + b$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

La salida es una combinación lineal de las entradas más el intercepto; no se utiliza una función sigmoide. Los 70 pesos y el intercepto se inicializan en cero. El gradiente indica la dirección de crecimiento local de la función de costo; el descenso de gradiente actualiza los parámetros en la dirección opuesta, con un tamaño de paso controlado por la tasa de aprendizaje α . Boyd y Vandenberghe presentan esa dirección y la actualización general en la sección 9.3. [3] Aquí se utiliza una tasa fija y todo el conjunto de entrenamiento en cada actualización; no se implementa la búsqueda de paso descrita en su algoritmo. Al derivar nuestro MSE se obtiene:

$$\nabla_w MSE = \frac{2}{n} X^T (\hat{y} - y)$$

$$\nabla_b MSE = \frac{2}{n} \sum_{i=1}^n (\hat{y}_i - y_i)$$

$$w \leftarrow w - \alpha \nabla_w MSE$$

$$b \leftarrow b - \alpha \nabla_b MSE$$

El MSE de este modelo lineal es convexo respecto a los parámetros: mínimos cuadrados es un caso de optimización convexa, como se establece en la sección 1.3 de Boyd y Vandenberghe. [3] Esta propiedad no garantiza que la ejecución de 5,000 épocas alcance el mínimo; la tasa y el avance efectivo de la optimización también intervienen. No se presenta como una conclusión de las curvas observadas.

El MSE inicial fue 14,619,901.40. Con $\alpha=0.01$, la primera actualización llevó el intercepto a aproximadamente 65.3083 y el MSE de entrenamiento a 13,821,118.92. Se registró la pérdida de entrenamiento y validación desde la época cero y después de cada actualización. Validación se utilizó para evaluar las configuraciones, sin participar en el cálculo de gradientes.

4.3 Métricas de evaluación

La función optimizada es el MSE, que promedia errores cuadrados y penaliza más los errores grandes. Sus unidades son vehículos al cuadrado. RMSE devuelve esa magnitud a las unidades del conteo horario, mientras que MAE resume la diferencia absoluta promedio. Estas dos últimas medidas se describen en la sección 5.8 de Hyndman y Athanasopoulos. [6]

$$RMSE = \sqrt{\frac{1}{n} \sum_i (\hat{y}_i - y_i)^2}$$

$$MAE = \frac{1}{n} \sum_i |\hat{y}_i - y_i|$$

El coeficiente de determinación compara la suma de errores cuadrados con la variación de los valores reales respecto a su media en el conjunto evaluado. También se calculó manualmente:

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

Para un objetivo no constante, un R^2 de 1 corresponde a predicciones perfectas, 0 al error de predecir la media del conjunto evaluado y un valor negativo a un error mayor que esa referencia. R^2 no es accuracy ni un porcentaje de predicciones correctas. [5] RMSE, MAE y R^2 se utilizan para evaluar; no sustituyen el MSE en los gradientes. La consulta de esa documentación fue únicamente conceptual: las métricas y el modelo se programaron manualmente, sin usar scikit-learn. El modelo suma efectos de las entradas: no se implementaron interacciones entre hora y día de la semana.

5. Resultados y limitaciones

5.1 Ajustes manuales y comparación de configuraciones

Cada experimento comenzó desde cero, conservando las mismas entradas y divisiones. Primero se modificó el número de épocas con tasa de aprendizaje 0.01; después se evaluó una tasa de 0.05 durante 5,000 épocas. Las cifras se muestran redondeadas.

Tabla 5. Configuraciones evaluadas

Tasa	Épocas	MSE ent.	MSE val.
0.01	100	3,381,793.82	3,197,566.53
0.01	1,000	1,417,317.47	1,322,054.62
0.01	3,000	871,444.86	825,483.02
0.01	5,000	813,717.58	777,717.01
0.05	5,000	673,616.96	649,892.16
Tasa	Épocas	R ² ent.	R ² val.
0.01	100	0.1454	0.1725
0.01	1,000	0.6418	0.6579
0.01	3,000	0.7798	0.7864
0.01	5,000	0.7944	0.7987
0.05	5,000	0.8298	0.8318

La configuración con tasa 0.05 y 5,000 épocas se seleccionó como candidata entre las evaluadas, por presentar el menor MSE de validación. No se afirma que sea óptima ni que haya alcanzado convergencia. Como referencia de su evolución, los registros disponibles son:

Tabla 6. Evolución de la configuración seleccionada

Época	MSE ent.	MSE val.
500	908,082.76	856,856.49
1,000	813,694.24	777,704.48
1,500	779,240.54	747,890.46
2,000	753,851.36	724,945.36
2,500	733,526.55	706,214.37
3,000	716,842.79	690,664.65
3,500	702,994.33	677,663.97
4,000	691,432.59	666,758.96
4,500	681,747.41	657,596.82
5,000	673,616.96	649,892.16

Las pérdidas descendieron y permanecieron cercanas durante estas ejecuciones. No se observa una divergencia creciente entre ellas, pero esto no demuestra ausencia de sobreajuste ni constituye una cuantificación de sesgo y varianza.





Figura 1. Evolución del MSE de entrenamiento y validación del modelo ajustado y comparación de las tasas de aprendizaje 0.01 y 0.05 durante 5,000 épocas. La disminución de las pérdidas describe el avance de la optimización, sin certificar convergencia. Fuente: elaboración propia a partir de la ejecución de los scripts.

5.2 Evaluación de la configuración fijada

La tasa de 0.05 y las 5,000 épocas se fijaron antes de evaluar prueba. Se utilizaron los parámetros aprendidos con entrenamiento, sin reentrenar para esa evaluación ni ajustar la configuración a partir de los resultados de prueba. Además de MSE y R², se reportan RMSE, raíz del MSE, y MAE, promedio de los errores absolutos. RMSE y MAE se expresan en vehículos del conteo horario.

Evaluar fuera de entrenamiento permite distinguir el ajuste a datos usados para aprender del desempeño sobre observaciones reservadas, principio explicado por Hyndman y Athanasopoulos. [6] Esta referencia respalda el criterio de evaluación; no convierte el experimento con clima observado en un pronóstico meteorológico ni elimina la limitación de la exploración previa al reparto.

Tabla 7. Evaluación final

Conjunto	MSE	R ²
Entrenam.	673,616.9567	0.8298
Validación	649,892.1629	0.8318
Prueba	626,723.0078	0.8400

Conjunto	RMSE	MAE
Entrenam.	820.7417	605.8012
Validación	806.1589	596.9254
Prueba	791.6584	583.5983

El MAE de prueba indica una diferencia absoluta promedio de aproximadamente 583.6 vehículos por conteo horario. No representa un límite garantizado para cada predicción. El menor error agregado de prueba no demuestra por sí solo ausencia de sobreajuste, dado que los conjuntos corresponden a periodos distintos y presentan distribuciones potencialmente diferentes.

5.3 Diagnóstico por hora y día

Se definió el error como predicción menos valor real. La comparación de ambas tasas a 5,000 épocas mostró que la mejora global no fue uniforme entre horarios. Se utilizó además el error absoluto medio (MAE) como resumen diagnóstico por grupo, distinto de la función de pérdida utilizada para entrenar.

Tabla 8. Errores por hora

Hora	Medida	Tasa 0.01	Tasa 0.05
00:00	Error medio	1,877.1	903.9
00:00	MAE	1,888.4	1,123.0
06:00	MAE	1,561.0	1,524.2
07:00	Error medio	-77.1	-13.8
07:00	MAE	1,656.1	1,621.6

A las 07:00, un error medio cercano a cero no implica errores individuales pequeños: los valores positivos y negativos pueden cancelarse. Para la configuración candidata, el desglose de esa hora muestra subestimación en días laborales y sobreestimación durante el fin de semana:

Tabla 9. Errores a las 07:00 por día

Día a las 07:00	N val.	Error val.	Error ent.
Lunes	36	-799.5	-1,083.4
Martes	36	-1,002.2	-1,165.9
Miércoles	36	-1,110.4	-1,146.9
Jueves	37	-1,032.7	-1,072.2
Viernes	37	-948.4	-875.3
Sábado	36	2,333.8	2,300.7
Domingo	35	2,589.6	2,611.7

La repetición del patrón en entrenamiento y validación es compatible con una limitación de la representación aditiva: el modelo no permite un efecto específico de cada combinación hora-día. Sin embargo, no demuestra que esta sea la única causa del error. No se implementaron interacciones en esta entrega. Algunas horas empeoraron en MAE al aumentar la tasa, por lo que la selección se fundamenta en el MSE global de validación y no en una mejora universal de cada grupo.





Figura 2. Diagnóstico de errores en validación. En el panel superior se comparan el error promedio y el MAE por hora; en el panel inferior se muestra el error promedio a las 07:00 por día de la semana. El error se define como predicción menos valor real: los valores negativos indican subestimación y los positivos, sobreestimación. La compensación entre días laborales y fines de semana explica que un error promedio cercano a cero pueda coexistir con un MAE elevado. Fuente: elaboración propia a partir de la ejecución de los scripts.

5.4 Comparación de grupos de variables

Después de la primera evaluación de prueba se realizó un análisis adicional utilizando únicamente entrenamiento y validación. Cada configuración se inició con parámetros en cero y se entrenó durante 5,000 épocas con tasa 0.05. No se utilizó una nueva evaluación de prueba para escoger grupos ni se modificó la configuración del modelo completo a partir de prueba.

Tabla 10. Comparación de grupos de variables

Entradas	N	MSE ent.	MSE val.
Temporales	29	710,942.5093	693,275.8650
Temporal + festivos	30	685,067.0922	661,644.8891
Temporal + clima	69	698,913.9678	677,753.6050
Completa	70	673,616.9567	649,892.1629
Entradas	N	R ² ent.	R ² val.
Temporales	29	0.8203	0.8206

Entradas	N	R ² ent.	R ² val.
Temporal + festivos	30	0.8269	0.8288
Temporal + clima	69	0.8234	0.8246
Completa	70	0.8298	0.8318

El grupo temporal incluye los 23 indicadores horarios y seis de día. El grupo de clima añade temperatura, lluvia, nubosidad y 37 indicadores meteorológicos. Bajo el mismo presupuesto de entrenamiento, añadir festividades redujo el MSE de validación 4.56% respecto al grupo temporal; añadir clima lo redujo 2.24%, y el modelo completo, 6.26%. Esto aporta evidencia de contribución predictiva incremental de los grupos en este experimento, sin establecer causalidad, importancia de cada variable individual ni significancia estadística.

Durante las últimas 500 épocas, el MSE de validación todavía disminuyó 1.1169%, 1.1628%, 1.1295% y 1.1716%, respectivamente. Por tanto, la comparación corresponde a un presupuesto fijo de optimización y no a soluciones con convergencia certificada. Su carácter posterior a la evaluación inicial de prueba debe distinguirse de la selección original de la configuración.





Figura 3. Comparación de grupos de variables durante las 5,000 épocas y detalle de las últimas 1,000. Todas las configuraciones utilizaron la misma tasa de aprendizaje de 0.05 y el mismo presupuesto de entrenamiento. Las curvas permiten comparar su evolución bajo ese presupuesto, sin certificar que hayan alcanzado su mínimo. Fuente: elaboración propia a partir de la ejecución de los scripts.

5.5 Diagnóstico de sesgo, varianza y ajuste

Como referencia conceptual, el subajuste describe una representación insuficiente de los patrones de los datos, mientras que el sobreajuste supone aprender particularidades del entrenamiento que no se trasladan adecuadamente a otros datos. [4] Las valoraciones siguientes son interpretaciones cualitativas de los experimentos del proyecto; la fuente no establece sus niveles de sesgo o varianza.

El modelo presenta un ajuste global útil para estimar el volumen horario, acompañado de limitaciones locales. Se valora su sesgo como moderado en términos cualitativos, considerando los errores sistemáticos de las 07:00 y la representación aditiva de hora y día. La subestimación de días laborales y sobreestimación de fines de semana también aparecen en entrenamiento, lo que es compatible con subajuste en esos patrones. Esta valoración no es una estimación formal del sesgo estadístico. Además, como las pérdidas siguen disminuyendo al finalizar las 5,000 épocas, no puede atribuirse todo el error restante a la estructura del modelo: la optimización todavía podría influir.

La cercanía entre los resultados de entrenamiento y validación sugiere baja varianza aparente, sin evidencia de sobreajuste marcado durante las ejecuciones observadas. Sin embargo, no se entrenaron modelos sobre múltiples muestras para medir la sensibilidad de sus predicciones, por lo que no se ha estimado formalmente la varianza. Que la pérdida de validación se mantenga por debajo de entrenamiento tampoco prueba ausencia de sobreajuste: los conjuntos abarcan periodos distintos y pueden diferir en dificultad y distribución.




Figura 4. MSE de entrenamiento y validación con tasa 0.05: historial completo en el panel superior y detalle de las épocas 4,000-5,000 en el panel inferior. El panel inferior amplía la escala vertical del mismo MSE para mostrar el descenso final; no representa otra métrica. Ambas pérdidas continúan disminuyendo, sin convergencia confirmada. Fuente: elaboración propia a partir de la ejecución de los scripts, sin nueva evaluación de prueba.

5.6 Límites de la evidencia

La validación se utilizó repetidamente para seleccionar configuraciones. Aunque la configuración se fijó antes de evaluar prueba, la exploración y el vocabulario meteorológico del conjunto completo influyeron previamente en las decisiones de representación. Persisten incertidumbres en temperaturas sospechosas, discrepancias entre registros horarios, cobertura de festividades, categorías meteorológicas raras y huecos temporales. La consolidación horaria constituye una decisión metodológica con pérdida de información, no una corrección comprobada de todas las mediciones.

La convergencia del entrenamiento no está certificada y los errores por horario muestran limitaciones, particularmente en medianoche, a las 06:00 y en la diferencia entre días laborales y fines de semana a las 07:00. La comparación de grupos examina aporte predictivo bajo las condiciones del experimento, pero no prueba causalidad ni identifica la contribución individual de cada variable. Se trabaja exclusivamente con clima observado; los pronósticos meteorológicos quedan fuera del alcance y no constituyen una tarea pendiente de esta entrega.

6. Implementación de Random Forest con framework

6.1 Justificación y fundamento teórico

El diagnóstico del modelo lineal mostró una limitación concreta: a las 07:00 subestimaba los días laborales y sobreestimaba los fines de semana. Este patrón sugiere que el efecto de una hora depende del día de la semana. Una regresión lineal con indicadores separados suma ambos efectos, pero no genera automáticamente una regla específica para cada combinación. Por esa razón se eligió Random Forest como segunda implementación de regresión, no únicamente para buscar una métrica mayor.

Un árbol de regresión divide sucesivamente el espacio de entradas mediante reglas y asigna a cada región una predicción numérica. Random Forest entrena muchos árboles sobre muestras generadas con reemplazo y considera subconjuntos de variables durante la construcción. La predicción final es el promedio de los árboles. Este ensamble puede representar umbrales e interacciones sin programarlas de forma explícita y el promedio reduce la variabilidad de un árbol individual. [7, 8]

Se utilizó RandomForestRegressor de scikit-learn con `random_state=42` para reproducibilidad. No se normalizaron las variables: las divisiones de los árboles dependen del orden y de umbrales dentro de cada entrada, no de distancias ni de un descenso de gradiente sensible a sus escalas. El modelo recibió las mismas 70 entradas y las mismas particiones cronológicas que la regresión manual.

6.2 Ajuste de hiperparámetros

Se definieron doce configuraciones antes de consultar sus resultados. Se modificaron cuatro hiperparámetros: número de árboles, profundidad máxima, mínimo de observaciones por hoja y proporción de variables consideradas en cada división. El número de árboles controla el tamaño del ensamble; la profundidad y el mínimo por hoja regulan su complejidad; y `max_features` introduce diversidad entre árboles. La selección se realizó exclusivamente por el menor MAE de validación.

Tabla 11. Configuraciones de Random Forest

Configuración	Árboles	Profundidad máxima	Mínimo por hoja
Base	100	Sin límite	1
200 árboles	200	Sin límite	1
Profundidad 10	100	10	1
Profundidad 30	100	30	1
Mínimo hoja 5	100	Sin límite	5
Mínimo hoja 10	100	Sin límite	10
Variables sqrt	100	Sin límite	1
Combinada	200	20	2

Configuración	MAE validación	R ² val.
Base	271.59	0.9479
200 árboles	270.85	0.9480
Profundidad 10	741.92	0.6752
Profundidad 30	262.46	0.9495
Mínimo hoja 5	252.66	0.9539
Mínimo hoja 10	247.05	0.9555
Variables sqrt	312.83	0.9354
Combinada	442.11	0.8495

La tabla presenta una selección representativa de las doce pruebas; el programa exporta todas. La mejor configuración fue 100 árboles, profundidad sin límite, mínimo de diez observaciones por hoja y todas las variables disponibles en cada división. Aumentar el mínimo por hoja suavizó las predicciones y mejoró validación respecto al modelo base. En cambio, limitar la profundidad a 10 produjo subajuste. Que una configuración más compleja no sea siempre mejor evidencia la necesidad de seleccionar con validación y no con entrenamiento.




Figura 5. MAE de validación de las doce configuraciones evaluadas. La selección se realizó antes de calcular las métricas finales de prueba y correspondió a `min_samples_leaf=10`. Fuente: elaboración propia a partir de la ejecución de `modelo_random_forest.py`.

6.3 Resultados finales y comparación

Una vez fijada la configuración, se calcularon sus métricas en los tres conjuntos. Entrenamiento y validación presentan resultados cercanos, mientras que prueba obtiene un error ligeramente menor. Esta cercanía no muestra una separación típica de sobreajuste marcado; no obstante, se trata de una sola división temporal y no de una medición formal de la varianza.

Tabla 12. Métricas finales de Random Forest

Conjunto	MSE	R ²
Entrenam.	166,290.78	0.9580
Validación	171,938.38	0.9555
Prueba	159,133.56	0.9594

Conjunto	RMSE	MAE
Entrenam.	407.79	243.27
Validación	414.65	247.05
Prueba	398.92	238.61

Tabla 13. Comparación final de modelos

Modelo en prueba	MSE	R ²
Regresión lineal manual	626,723.01	0.8400
Random Forest	159,133.56	0.9594

Modelo en prueba	RMSE	MAE
Regresión lineal manual	791.66	583.60
Random Forest	398.92	238.61

Frente a la regresión manual, Random Forest redujo el MSE 74.61%, el RMSE 49.61% y el MAE 59.11%. El R² aumentó 0.1194, equivalente a 11.94 puntos porcentuales. La mejora no significa que Random Forest sea universalmente superior, sino que su capacidad para modelar relaciones no lineales e interacciones se ajusta mejor a la estructura observada en este problema.




Figura 6. Valores reales y predicciones del Random Forest seleccionado durante las primeras 168 observaciones de validación. La figura permite observar el seguimiento de los ciclos horarios; no sustituye las métricas calculadas sobre las 6,085 observaciones. Fuente: elaboración propia.

6.4 Errores temporales e importancia de grupos

El mayor MAE horario del Random Forest en validación fue 409.16 vehículos a las 07:00, seguido de 403.31 a las 08:00. Aunque esas horas continúan siendo difíciles, el MAE de las 07:00 se redujo desde 1,621.6 en la regresión manual. Además, el error medio por día a esa hora dejó de mostrar la separación extrema entre días laborales y fines de semana: varió entre -60.80 y 219.85 vehículos, aunque el MAE por día todavía alcanzó 665.71 el lunes. Esto respalda que el bosque aprendió parte de la interacción hora-día que faltaba en la estructura lineal.




Figura 7. Diagnóstico temporal del Random Forest en validación. El panel superior presenta el MAE por hora y el inferior, el error promedio a las 07:00 por día de la semana. Los valores positivos indican sobreestimación y los negativos, subestimación. Fuente: elaboración propia.

Las importancias internas del bosque sumaron 97.09% para indicadores temporales, 1.48% para clima y 1.42% para festividades. Esto indica que, dentro del modelo ajustado y con esta codificación, las variables temporales participaron en la mayor parte de la reducción de impureza de los árboles. No representa causalidad, significancia estadística ni una contribución independiente: las variables correlacionadas pueden repartirse importancia y esta medida se calcula a partir de la estructura entrenada. La documentación de scikit-learn advierte además que las importancias basadas en impureza pueden favorecer ciertas variables. [8]




Figura 8. Importancia interna acumulada por grupo en el Random Forest seleccionado. Su lectura es predictiva y relativa al modelo; no demuestra que el clima o las festividades carezcan de efecto real. Fuente: elaboración propia.

6.5 Alcance de la comparación

La comparación mantiene el mismo objetivo, las mismas 70 entradas y las mismas fronteras temporales, por lo que las diferencias se atribuyen al método de aprendizaje bajo este diseño. Sin embargo, el conjunto de prueba ya había sido consultado durante la entrega de la regresión manual antes de desarrollar el Random Forest. Por tanto, la evaluación del segundo modelo es reproducible y no se utilizó para escoger sus hiperparámetros, pero no debe describirse como una prueba completamente desconocida durante todo el proyecto.

El Random Forest se implementó con una biblioteca, mientras que la regresión se programó manualmente. Esta diferencia es deliberada: el primer modelo demuestra los fundamentos del aprendizaje y el segundo permite evaluar una familia más flexible. Ninguno utiliza pronósticos meteorológicos; ambos trabajan con condiciones observadas incluidas en el dataset.

7. Conclusiones

El proyecto logró estimar el conteo vehicular horario de la I-94 mediante dos aproximaciones complementarias. El ETL transformó 48,204 registros originales en 40,564 observaciones horarias con 70 entradas. Definir la hora como unidad de análisis evitó que una misma medición de tráfico apareciera repetida por la existencia de varias descripciones meteorológicas; extender las etiquetas festivas a todas las horas de sus fechas evitó representar una festividad únicamente a medianoche.

Las entradas temporales obtuvieron por sí solas un R^2 de validación de 0.8206. Respecto a ese grupo, añadir festividades redujo el MSE 4.56%, añadir clima lo redujo 2.24% e incluir ambos grupos lo redujo 6.26%. Los resultados respaldan un aporte predictivo incremental bajo el mismo presupuesto de entrenamiento, sin establecer causalidad ni atribuir el cambio a una variable individual.

La regresión manual confirmó que el programa aprende y produce predicciones: su configuración ajustada alcanzó en prueba un MAE de 583.60 vehículos y un R^2 de 0.8400. El análisis por hora también reveló su principal límite: a las 07:00 combinaba subestimaciones en días laborales con sobreestimaciones en fines de semana, patrón que una

estructura aditiva de hora y día no representó adecuadamente.

Random Forest atendió directamente esa limitación al aprender divisiones e interacciones no lineales. La configuración seleccionada mediante validación alcanzó un MAE de prueba de 238.61 vehículos y un R^2 de 0.9594. Respecto a la regresión manual, redujo el MAE 59.11% y el RMSE 49.61%. A las 07:00, el MAE de validación disminuyó de 1,621.6 a 409.16 vehículos y desapareció la separación extrema de signos entre días laborales y fines de semana. Por ello, la mejora no se limita a una métrica global: corrige parcialmente un patrón concreto detectado en el primer modelo.

Las importancias internas del bosque concentraron 97.09% en variables temporales, lo que coincide con los ciclos horarios identificados durante la exploración. Clima y festividades conservaron una participación predictiva menor dentro del modelo, pero la medida no demuestra causalidad ni irrelevancia real. La cercanía entre entrenamiento, validación y prueba no muestra sobreajuste marcado en la partición utilizada, aunque una sola división temporal no permite descartarlo de manera absoluta.

En relación con el objetivo, la implementación permite anticipar el volumen esperado para una hora cuando se proporcionan las mismas clases de entradas con las que fue entrenada. Sus resultados pueden apoyar la identificación de periodos de mayor demanda y la planeación informativa o de mantenimiento. No determina por sí sola congestión, rutas alternas ni condiciones de seguridad, y no incorpora un servicio de pronóstico meteorológico.

Referencias

- [1] Hogue, J. (2019). Metro Interstate Traffic Volume [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5X60B>. Ficha oficial del dataset (<https://archive.ics.uci.edu/dataset/492/metro+interstate+traffic+volume>).
- [2] Dive into Deep Learning. (s. f.). 3.1. Linear Regression. Capítulo en línea (https://d2l.ai/chapter_linear-regression/linear-regression.html). Consulta: 8 de septiembre de 2026.
- [3] Boyd, S., y Vandenberghe, L. (2004). Convex Optimization. Cambridge University Press. Secciones 1.3 y 9.3. Libro disponible en el sitio de los autores (<https://web.stanford.edu/~boyd/cvxbook/>). Consulta: 8 de septiembre de 2026.
- [4] Google for Developers. (s. f.). Overfitting. Machine Learning Crash Course. Lección en línea (<https://developers.google.com/machine-learning/crash-course/overfitting/overfitting>). Consulta: 8 de septiembre de 2026.
- [5] Scikit-learn. (s. f.). Metrics and scoring: quantifying the quality of predictions. Apartados de métricas de regresión. Documentación en línea (https://scikit-learn.org/stable/modules/model_evaluation.html). Consulta: 8 de septiembre de 2026.
- [6] Hyndman, R. J., y Athanasopoulos, G. (2021). Forecasting: Principles and Practice (3.^a ed.). OTexts. Sección 5.8, «Evaluating point forecast accuracy». Texto en

línea (<https://otexts.com/fpp3/accuracy.html>). Consulta: 8 de septiembre de 2026.

- [7] Breiman, L. (2001). Random Forests. Machine Learning, 45, 5-32. <https://doi.org/10.1023/A:1010933404324>.
- [8] Scikit-learn developers. (s. f.). RandomForestRegressor y Ensembles: Gradient boosting, random forests, bagging, voting, stacking. Documentación oficial (<https://scikit-learn.org/stable/modules/ensemble.html>). Consulta: 15 de septiembre de 2026.